Zurück zum Fall

Situationen · Lesefassung

THEMA 1 / ARBEITSBESTAND UND PUBLIKATION

Eine Ablage für Forschung – eine Publikation für andere.

Eine passende Forschungsablage ist noch keine Datenpublikation.

Elifs Frage

Lea gibt Elif Zugang zu ihrem Forschungsrepo. Elif möchte Reimformen untersuchen und fragt: „Welchen TEI-Ordner soll ich nehmen?“

Für Leas Untersuchung sinnvoll

Das Repo bewahrt die übernommenen Quellen, die vereinheitlichten Daten und die festgehaltenen Eingaben einzelner Studien. Dasselbe Buch liegt dadurch in mehreren begründeten Fassungen vor. Diese Struktur dokumentiert Leas Forschungsweg. Elif braucht dagegen einen eindeutig bezeichneten Korpusbestand für eine neue Untersuchung.

MERKEN

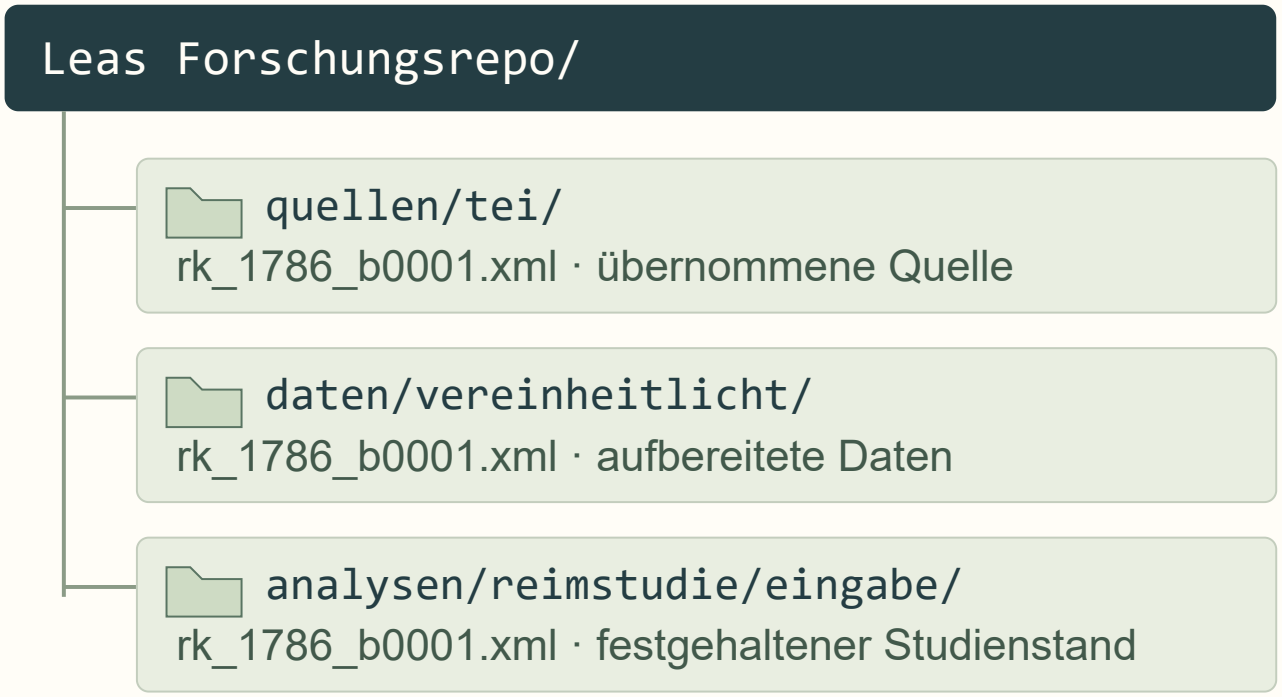
Ein Publikationsrepositorium ist kein veröffentlichtes Forschungsrepo!

Eine gute Forschungsablage erklärt, wie eine Studie entstanden ist. Die Datenpublikation erklärt, welchen Bestand andere für neue Studien verwenden sollen. Dafür richten wir ein eigenes kuratiertes Korpusrepo ein.

▼ Beispiel und Tipp

Beispiel: Forschungsrepo: quellen/tei/rk_1786_b0001.xml → daten/vereinheitlicht/rk_1786_b0001.xml → analysen/reimstudie/eingabe/rk_1786_b0001.xml. Publikationsrepo: genau ein maßgeblicher Korpusstand unter data/tei/rk_1786_b0001.xml.

Tipp: Publikationskonzept vor der ersten Freigabe in Git festhalten.



▼ Grafik als Text lesen

Leas Forschungsablage

1. Leas Forschungsrepo/
2. quellen/tei/
3. rk_1786_b0001.xml · übernommene Quelle
4. daten/vereinheitlicht/
5. rk_1786_b0001.xml · aufbereitete Daten
6. analysen/reimstudie/eingabe/
7. rk_1786_b0001.xml · festgehaltener Studienstand
8. Ein Forschungsweg: Quelle → Aufbereitung → Studienstand.

Für die eigene Studie sind die getrennten Bearbeitungsstände sinnvoll.

ZWEI ZWECKE · ZWEI ANGEBOTE

Für die Studie sinnvoll – für die Publikation anders aufbereitet

Im Forschungsrepo	Warum dort sinnvoll?	Im Publikationsrepo
quellen/tei/rk_1786_b0001.xml	Übernommene Fassung für den Vergleich mit der Aufbereitung.	Quellennachweis und Herkunft in Metadaten; kein konkurrierender Korpusordner.
daten/vereinheitlicht/rk_1786_b0001.xml	Aufbereiteter Stand für Leas Auswertungen.	Nach Prüfung der maßgebliche Bestand unter **data/tei/rk_1786_b0001.xml**.
analysen/reimstudie/eingabe/rk_1786_b0001.xml	Festgehaltene Eingabe, mit der ein Studienergebnis entstand.	Die Studie nennt Release und Auswahl. Ihr eingefrorener Ausschnitt wird nicht als zweite Korpusfassung angeboten.

Die Forschungsablage ist für ihren Zweck angemessen. Für die Publikation werden eindeutiger Einstieg, geltende Regeln und ein freigegebener Bestand ergänzt.

Die vollständige empfohlene Publikationsstruktur ansehen ↑

SO WÜRDEN WIR ES MACHEN

Das können Sie übernehmen

1. Publikationskonzept vor der ersten Freigabe in Git festhalten.
2. Geprüfte Buchdateien aus daten/vereinheitlicht nach data/tei des Publikationsrepos übernehmen.
3. README, Regeln und Einstieg ergänzen; den ersten Release extern ausprobieren lassen.

Konkretes Beispiel

Forschungsrepo: quellen/tei/rk_1786_b0001.xml → daten/vereinheitlicht/rk_1786_b0001.xml → analysen/reimstudie/eingabe/rk_1786_b0001.xml. Publikationsrepo: genau ein maßgeblicher Korpusstand unter data/tei/rk_1786_b0001.xml.

Erledigt, wenn: Eine neue Nutzerin erkennt ohne Rückfrage, welche Dateien und welche Version sie untersuchen soll.

Git hilft dabei: Git hält Publikationskonzept, Daten und Korrekturen nachvollziehbar zusammen. GitHub macht README, Releases, Issues und geprüfte Beiträge zugänglich. Welche Arbeitsgeschichte öffentlich wird, entscheidet das Team bewusst.

▼ Für Workshop und Selbststudium: eine Frage

Was müsste jemand wissen, der heute ohne uns mit unserem Repo zu forschen beginnt?

THEMA 2 / QUALITÄT PRÜFEN

Das Skript läuft. Wo sind die Lösungen?

Ein Inhalt kann verschwinden, obwohl die bisherige Auswertung weiterläuft.

Eine unbemerkte Auslassung

Leas neue Aufbereitung übernimmt die Rätseltexte, verliert aber den Lösungsteil: Er war in der bisherigen TEI-Struktur in einem getrennten XML-Element erfasst und ist in den neu erzeugten TEI-Daten nicht mehr enthalten. Ihre bisherige Python-Auswertung zählt nur Rätsel und Verse: Die Zahlen bleiben gleich. Erst beim Lesen einer Seminaraufgabe fehlt die Antwort.

Den Fehler eingrenzen

Lea und Jonas vergleichen in Git die Fassungen vor und nach der Konvertierung. Dabei erkennen sie, dass die geänderte Konvertierung das XML-Element mit den Lösungen nicht übernimmt. Sie korrigieren das Verfahren und erstellen einen kleinen neuen Prüffall, der genau diesen Fehler nachstellt: Ein Rätsel mit einem getrennt ausgezeichneten Lösungsteil muss die Konvertierung vollständig durchlaufen. Der Test prüft anschließend, ob Lösung und Zuordnung erhalten geblieben sind.

MERKEN

Eine erfolgreiche Analyse beweist keine vollständigen Daten.

Wir prüfen Struktur, Beziehungen und Inhaltserhalt getrennt. Automatische Tests werden durch einen gezielten Quellenvergleich ergänzt.

▼ Beispiel und Tipp

Beispiel: Zwei Rätsel und zwei Lösungen vor der Verarbeitung; zwei Rätsel und keine Lösung danach. XML und Demo-Schema bestehen, der Bestandsvergleich meldet den Verlust.

Tipp: Vor und nach einer Transformation alle zu übernehmenden Elemente und Inhalte, IDs und Verweise vergleichen.

DAS EIGENE SKRIPT BRAUCHT DIE LÖSUNGEN NICHT

Zwei Lösungen fehlen. Die Rätselzahl bleibt gleich.

Die neue Verarbeitung übernimmt den Hauptteil, lässt den Lösungsteil aber weg. Der ausgeführte Beispieltest zeigt:

Prüfung	Vorher	Nachher
XML und Demo-Schema	Bestanden	Bestanden
Gezählte Rätsel	2	2
Erhaltene Lösungen	2	0
Erwarteter Bestand erhalten?	Ja	**Nein**

Zwei Rätsel und zwei Lösungen. Der bekannte Bestand ist vollständig.

```
<!-- Im Vergleich verschwindet ein vollständiger Teil: -->
- <back>
-   <!-- Zwei Lösungen mit Zuordnung zu ihren Rätseln -->
- </back>
```

Was ergänzt die Prüfung? Bestand und Verweise vergleichen, unerwartete Verluste untersuchen und gefährdete Stellen gegen die Quelle lesen. Auch gültige Dateien können

fachlich falsch oder unvollständig sein.

Anzeige des tatsächlich ausgeführten künstlichen Beispiels. Die Auswahl führt keine XML-Prüfung im Browser aus. Vollständige Dateien und Diff stehen im Beispielpaket.

▼ Ein zweiter Fehler: Lösungen als Rätsel gezählt

AUSPROBIEREN · KÜNSTLICHE BEISPIELDATEIEN

Was ist eigentlich grün?

Die Vorlage enthält zwei Rätsel und zwei getrennte Lösungen. Das ursprüngliche Schema erlaubt Sammlungen ohne Lösungen; es kennt diese Quelle nicht.

4 als Rätsel gezählte Einträge, 0 Lösungen. Schema und vorhandene Verweise: bestanden. Bekannte Quellenmerkmale: nicht erfüllt.

Ausgeführter Prüfbericht der künstlichen Beispiele

Prüfung	Fehlerhafter Import	Korrigierter Import
Demo-Schema	Bestanden	Bestanden
IDs und vorhandene Verweise	Bestanden	Bestanden
Rätsel / Lösungen	4 / 0	2 / 2
Bekannte Quellstruktur	Nicht erfüllt	Erfüllt

▼ Die Zuordnung im TEI ansehen

```
<div type="riddle" xml:id="riddle-demo-001">
  <p>Ich habe Zähne und esse nicht. Was bin ich?</p>
</div>
<!-- Lösung im getrennten Lösungsteil -->
<item corresp="#riddle-demo-001">Der Kamm.</item>
```

Das kleine Relax-NG-Schema und die Verweisprüfungen wurden tatsächlich ausgeführt. Diese Anzeige liest den gespeicherten Prüfbericht; sie führt keine neue XML-Prüfung im

Browser aus. Ein vollständiges Korpusmodell braucht eine eigene dokumentierte TEI-Anpassung.

XML wohlgeformt?

▼ Beispiel und Tipp

Beispiel: Ein nicht geschlossenes Element verhindert das Einlesen einer XML-Datei.

Tipp: XML-Wohlgeformtheit automatisiert prüfen. Danach erst können weitere Prüfungen zuverlässig arbeiten.

→

Schema eingehalten?

▼ Beispiel und Tipp

Beispiel: Das Schema prüft, ob Elemente an der vorgesehenen Stelle vorkommen dürfen. Ein fehlender optionaler Lösungsteil kann trotzdem erlaubt sein.

Tipp: Das Schema mit dem dokumentierten Korpusmodell versionieren; fachliche Vollständigkeit zusätzlich prüfen.

→

Bestand und Verweise erhalten?

▼ Beispiel und Tipp

Beispiel: Nach dem Export gibt es weiterhin zwei Rätsel, aber statt zwei keine Lösungen.

Tipp: Erwartete Einheiten, Kennungen und Verweisziele vergleichen; jede unerwartete Abnahme untersuchen.

→

Ableitung geprüft?

▼ Beispiel und Tipp

Beispiel: Ein TXT-Export mit Lösungen hat mehr Wörter als ein Export nur der Rätsel.

Tipp: Erwartete Bestandteile und Ausschlüsse der Extraktion an einem kleinen Beispiel testen.

→
Stellen gegen Quelle gelesen?

▼ Beispiel und Tipp

Beispiel: Die Quelle trennt Rätsel und Lösungen, die Konvertierung muss diese Beziehung erhalten.

Tipp: Bei Änderungen an der Konvertierung gerade die betroffenen Quellstrukturen genau lesen.

→
Freigabe dokumentiert?

▼ Beispiel und Tipp

Beispiel: Ein Pull Request hält Änderung, bestandene Prüfungen und fachliche Zustimmung fest.

Tipp: Nur freigegebene Änderungen in den nächsten Release aufnehmen; bekannte Grenzen in den Releasenotizen nennen.

SO WÜRDEN WIR ES MACHEN

Das können Sie übernehmen

1. Vor und nach einer Transformation alle zu übernehmenden Elemente und Inhalte, IDs und Verweise vergleichen.
2. Im Pull Request den Diff und betroffene Quellstellen prüfen; unerwartete Verluste klären.
3. Den Fehlerfall als Regressionstest behalten und erst nach fachlicher Freigabe veröffentlichen.

Konkretes Beispiel

Zwei Rätsel und zwei Lösungen vor der Verarbeitung; zwei Rätsel und keine Lösung danach. XML und Demo-Schema bestehen, der Bestandsvergleich meldet den Verlust.

Erledigt, wenn: Der Prüflauf erkennt den bekannten Verlust; die Quellenkontrolle und Freigabe sind dokumentiert.

Git hilft dabei: Versionsvergleich und bezeichnete Werkzeugstände zeigen, wann Inhalte verloren gingen und welche Importe betroffen sind. Ein Regressionstest begleitet die Korrektur. Git bewahrt Änderungen; ihren fachlichen Sinn muss das Team prüfen.

▼ Für Workshop und Selbststudium: eine Frage

Welche Daten könnte unsere heutige Analyse verlieren, ohne dass sich ihr Ergebnis merklich ändert?

THEMA 3 / VERSIONEN UND FORSCHUNGSNACHWEIS

Gestern war das Ergebnis noch anders.

Wachsende Daten brauchen nachvollziehbare Fassungen.



Lea und Elif vergleichen zwei unterschiedlich umfangreiche Versionsmappen.Fiktive Szene · KI-generierte Illustration

Eine neue Grafik

Für ihre Publikation hat Elif den Versanteil im Korpus berechnet und eine Balkengrafik erzeugt, die ihr sehr aussagekräftig erschien. Etwas später möchte sie mit demselben Skript dieselbe Grafik in ausdrucksstärkeren Farben erzeugen. Doch die Balken zeigen ein unerwartetes Bild: Lea hat inzwischen weitere Sammlungen aufgenommen. Elifs Skript lädt stets den aktuellen Repositorystand.

Den verwendeten Stand wiederholen

Mit dem archivierten früheren Release und demselben Skript kann Elif die ursprüngliche Grafik wiederherstellen. Sie muss die verwendete Datenversion angeben, damit andere ihre Zahlen und Schlussfolgerungen nachvollziehen können. An ihren Schlussfolgerungen ändert der erweiterte Bestand nichts; einige Zahlen fallen allerdings weniger eindeutig aus als zuvor. Elif hält nun Datenfassung, Belegauswahl und Verfahren gemeinsam fest. Lea kann weiter Bücher ergänzen, während frühere Untersuchungen auf ihren bezeichneten Datenstand zurückgreifen können.

MERKEN

Eine Untersuchung braucht einen bestimmten Datenstand.

Wir veröffentlichen geprüfte Releases und erhalten sie unabhängig vom Git-Host. Forschende nennen zusätzlich Auswahl, Extraktion und Werkzeugfassung.

▼ Beispiel und Tipp

Beispiel: Demo-v1.0: 2 von 4 Rätseln sind Verse. Demo-v1.1: 8 von 10. Werden dieselben vier alten Belege ausgewählt, bleibt ihr Anteil bei 50 Prozent.

Tipp: Nach der Freigabe einen geschützten Tag und Release mit Bestands- und Änderungsnotizen anlegen.

BESTAND UND AUSWAHL GETRENNT BETRACHTEN

Was verändert die Verteilung?

Die beiden alten Buchdateien sind in beiden Fassungen bytegleich. Die neue Fassung ergänzt ein Buch mit sechs Versrätseln.

KorpusfassungAuswahl

2 von 4 Rätseln sind als Vers kodiert: 50 %. Der vollständige Bestand dieses Releases wird verglichen.

Versrätsel

Prosarätsel

Künstliche Bestände, keine historischen Forschungsergebnisse

Auswahl	Vers	Gesamt	Anteil
Demo-v1.0	2	4	50 %
Demo-v1.1	8	10	80 %
Demo-v1.1 · alte Belege	2	4	50 %

▼ Gleiche Daten – anderer Export?

Aus derselben korrigierten TEI-Datei liefern zwei XSLT-Auswahlen 20 bzw. 24 durch Leerraum getrennte Wörter. Die zweite Auswahl zählt Lösungen mit. Das ist ein technischer Demonstrationsbefund, keine historische Sprachstatistik.

Deshalb gehören Extraktionsregel, Auswahl und Werkzeugfassung zur Forschungsgrundlage.


```
{
  "id": "P03-DEMO-ANALYSE-01",
  "status": "künstliche Demonstration; keine archivierte historische
Datenpublikation",
  "corpus": {
    "release": "demo-v1.0",
    "path": "versionsvergleich/v1.0/data",
    "version_doi": null,
    "git_commit": null
  },
  "selection": {
    "book_ids": [
      "book-a",
      "book-b"
    ],
```

```
    "rule": "alle Rätsel der beiden genannten Beispielsammlungen"
  },
  "extraction": {
    "file": "xslt/raetseltexte-v1.xsl",
    "version": "demo-1",
    "includes_solutions": false,
    "includes_prefaces": false
  },
  "analysis": {
    "file": "run_demo.py",
    "measure": "Versrätsel / alle Rätsel",
    "definition": "riddle-div mit direktem lg = Vers; p = Prosa",
    "parameters": {
      "rounding": "keine Rundung der Bestandszahlen"
    }
  },
  "production_fields": "Bei einer tatsächlichen Forschungsanalyse werden
konkrete Version-DOI, erhaltene Commitreferenz und archivierte
Werkzeugstände ergänzt. Null ist hier ausdrücklich kein gültiges fertiges
Forschungszitat."
}
```


Für diese Demonstration sind DOI und Git-Commit ausdrücklich leer. Sie ist kein fertiges Forschungszitat und keine reale Datenpublikation.

Commit

Exakte technische Revision. Kann ein ungeprüfter Zwischenstand sein.

▼ Beispiel und Tipp

Beispiel: Ein Commit identifiziert die Änderung an einer Buchdatei, auch wenn sie noch nicht freigegeben ist.

Tipp: Commitnachrichten erklären Anlass und Umfang; den wissenschaftlichen Datenstand als Release bezeichnen.

→

Tag und Projekt-Release

Benannter, nach Projektregeln geprüfter Stand mit Zusammensetzung und Änderungshinweisen.

▼ Beispiel und Tipp

Beispiel: v1.1 benennt einen geprüften Stand und ergänzt die Liste neu aufgenommener Sammlungen.

Tipp: Veröffentlichte Tags schützen und nicht stillschweigend auf einen anderen Stand verschieben.

→

Archivierte Version

Erhaltenes Datenpaket mit Metadaten und Versionsidentifikator. Für Forschung die konkrete verwendete Fassung nennen.

▼ Beispiel und Tipp

Beispiel: Eine Versionsreferenz führt zum erhaltenen Datenpaket, mit dem die Untersuchung durchgeführt wurde.

Tipp: Für die Zitation die tatsächlich verwendete Version nennen.

SO WÜRDEN WIR ES MACHEN

Das können Sie übernehmen

1. Nach der Freigabe einen geschützten Tag und Release mit Bestands- und Änderungsnotizen anlegen.
2. Datenpaket samt Metadaten archivieren und den konkreten Versionsnachweis in den Zitierhinweis aufnehmen.
3. Für jede Analyse Release, Auswahl, Exportregel und Skriptfassung festhalten.

Konkretes Beispiel

Demo-v1.0: 2 von 4 Rätseln sind Verse. Demo-v1.1: 8 von 10. Werden dieselben vier alten Belege ausgewählt, bleibt ihr Anteil bei 50 Prozent.

Erledigt, wenn: Eine andere Person kann aus den bezeichneten Daten und Verfahren die Untersuchung wiederholen.

Git hilft dabei: Fixierte Daten- und Werkzeugstände machen den Vergleich wiederholbar. Git dokumentiert Bestandsänderungen; deren wissenschaftliche Bedeutung muss das Team erklären.

▼ Für Workshop und Selbststudium: eine Frage

Könnte jemand allein mit unseren Angaben dieselbe Forschungsgrundlage wieder zusammensetzen?

THEMA 4 / NACHNUTZUNG UND ANNOTATION

Ein Reim hilft dem Modell auf die Sprünge.

Zusatzannotation und Modellversuche bleiben ihrer Basis zugeordnet.



Studierende und Lea vergleichen Modellantworten und gedruckte Rätselverse. Fiktive Szene · KI-generierte Illustration

Eine Frage aus dem Seminar

Studierende lassen ein lokales Sprachmodell gereimte Zweizeiler lösen. In einer Gruppe dieser Rätsel ist die Lösung zugleich das fehlende Reimwort im zweiten Vers. „Versteht es das Rätsel oder ergänzt es nur den Reim?“ Um das zu untersuchen, vergleicht die Gruppe die Verse mit einer getrennt gespeicherten Prosabearbeitung, in der der Reimhinweis fehlt.

Aus Nutzung wird Anschlussforschung

Elif ergänzt in den für diese Untersuchung verwendeten Daten Form- und Wortannotation. Damit kennzeichnet sie insbesondere die Rätsel, deren Lösung das fehlende Reimwort ist. Bei einem späteren Workshop werden die so aufbereiteten Daten für einen Vergleich verschiedener Sprachmodelle genutzt. Es entsteht ein separates kleines Benchmark-Korpus: Welches Modell kann sprachliche Rätsel im Deutsch vergangener Sprachstufen lösen? Ein weiteres Experiment trainiert ein Sprachmodell mithilfe der Referenzdaten nach; auf den getrennt gehaltenen Testdaten erzielt es deutlich bessere Lösungsergebnisse. Das Team entscheidet, das gesamte vorhandene Korpus für solche Aufgaben aufzubereiten. Die Daten erhalten eine zusätzliche Annotationsschicht. TEI erlaubt, diese Schicht gesondert auszuzeichnen und mit den Basisdaten zu verknüpfen, ohne deren Texte zu verändern. Die erweiterte Fassung erhält eine neue Versionsnummer; Basisrelease, Annotation und Modellversuche bleiben nachvollziehbar miteinander verbunden.

MERKEN

Neue Forschung soll auf dem Korpus aufbauen können.

Unser Ausgangspunkt ist eine getrennt versionierte Zusatzannotation. Originale, Bearbeitungen, automatische Schichten und Modellversuche bleiben eindeutig unterscheidbar.

▼ Beispiel und Tipp

Beispiel: Basis: Korpus v1.0. Zusatz: Wortannotation 1.0 mit Bezug auf dessen Tokenisierung. Modelltest: Rätseltexte in testeingaben.jsonl, Referenzantworten getrennt in loesungen.jsonl.

Tipp: Annotation mit Basisrelease, Beleg- oder Wortankern und Erzeugungsverfahren beschreiben.

ZUSATZANNOTATION VERÖFFENTLICHEN

Unsere Empfehlung: eine eigene Annotationsschicht

Eigene Annotationsschicht

Unser Ausgangspunkt für zusätzliche automatische Annotation: eigene Version, konkreter Basisrelease, eindeutige Anker und dokumentierter Prüfstatus.

▼ Beispiel und Tipp

Beispiel: Eine Wortannotation nennt Korpus v1.0 und dessen Tokenisierung.

Tipp: Dies ist unser Ausgangspunkt für automatische Zusatzannotation. Verfahren und Prüfstatus sichtbar halten.

Beispiel: Die Wortannotation 1.0 nennt Korpus v1.0 als Basis und dokumentiert ihre Tokenisierung. Die TEI-Basis bleibt separat nutzbar.

▼ Vertiefung: Wann kommt ein anderer Weg in Betracht?

Im Haupt-TEI

Direkt im Basis-TEI, wenn die Redaktion das Modell fachlich erweitert. Die Änderung wird geprüft und mit einem neuen Basisrelease veröffentlicht.

▼ Beispiel und Tipp

Beispiel: Die Redaktion beschließt ein zusätzliches Element im Basismodell.

Tipp: Modelländerung, betroffene Dateien und Prüfungen gemeinsam versionieren und einen neuen Basisrelease erstellen.

Abgeleitetes Forschungskorpus

Für eine eigenständige neue Forschungsedition: eigenes Repo mit Herkunft, Auswahl und Transformationsnachweis. Diese Vertiefung braucht eigene Pflege.

▼ Beispiel und Tipp

Beispiel: Ein Anschlussprojekt wählt andere Einheiten und pflegt sie in einem eigenen Repo.

Tipp: Herkunft und Transformationen nachweisen; die Verantwortung für die neue Publikation benennen.

▼ Ausprobieren: Reimhinweis und Modellversuch

EIN REIM ALS HINWEIS

Was macht das Rätsel lösbar?

> Ich ordne Haare, nicht den Schlamm;
> mein Name fehlt: Es ist der […].

Künstliches Beispiel · fehlendes Reimwort als Lösung

Versuch: Geben wir dem Modell die gereimten Verse – oder eine bearbeitete Fassung ohne diesen Reimhinweis?

Versuchseingabe

Zwei Verse mit Reimhinweis auf „Schlamm“.

▼ Getrennte Referenzlösung ansehen

Kamm. Die Lösung steht in der Auswertungsdatei, nicht in der Testeingabe.

Ein Versuch braucht einen nachvollziehbaren Aufbau

1. Korpusrelease und Auswahl bezeichnen; überlieferte Texte und Bearbeitungen trennen.
2. Testeingaben ohne Lösungen exportieren; Referenzlösungen getrennt halten.
3. Trainings-/Testbezüge und ähnliche Rätsel prüfen. Unterschiedliche IDs garantieren noch keine Unabhängigkeit.
4. Modell, Parameter und Auswertungsregel vor dem Vergleich dokumentieren.

Ein Modell kann auch mit plausiblen anderen Antworten reagieren. Das muss die Auswertung berücksichtigen. Hier wird kein Modell ausgeführt und kein Leistungswert behauptet.

Kleines lokales Paket: Daten und Exportskript ↓

SO WÜRDEN WIR ES MACHEN

Das können Sie übernehmen

1. Annotation mit Basisrelease, Beleg- oder Wortankern und Erzeugungsverfahren beschreiben.
2. Automatische Herkunft und Prüfstatus angeben; Basisdaten ohne Zusatzschicht anbieten.
3. Bei Modellversuchen Testeingaben und Lösungen trennen; Trainings-/Testauswahl und verwandte Belege prüfen.

Konkretes Beispiel

Basis: Korpus v1.0. Zusatz: Wortannotation 1.0 mit Bezug auf dessen Tokenisierung. Modelltest: Rätseltexte in testeingaben.jsonl, Referenzantworten getrennt in loesungen.jsonl.

Erledigt, wenn: Die Annotation ist ihrer Basis zugeordnet und kann weggelassen werden; der Versuch ist dokumentiert.

Git hilft dabei: Basisrelease, Annotation und Versuchsskripte lassen sich über bezeichnete Fassungen verbinden. Issues und Pull Requests ermöglichen Rückfragen und geprüfte Beiträge; die Versionierung macht die Untersuchung nachvollziehbar.

▼ Für Workshop und Selbststudium: eine Frage

Welche neue Forschungsfrage wird durch unsere derzeitige Auszeichnung erschwert?

THEMA 5 / LOKALE NUTZUNG UND ÜBERGABE

Klappt es auch ohne Leas Rechner?

Ein frischer Download zeigt die stillen Voraussetzungen.



Jonas arbeitet anhand einer Anleitung, während Lea ihn selbst ausprobieren lässt.Fiktive Szene · KI-generierte Illustration

Ein Versuch ohne Zuruf

Jonas lädt den Release auf einen anderen Rechner und beginnt bei README. Das Beispiel erwartet noch Leas Netzlaufwerk. Im Team hatte das niemand bemerkt: Alle arbeiteten mit derselben Infrastruktur.

Der Einstieg wird verbessert

Lea ersetzt persönliche Pfade durch relative Pfade und dokumentiert Aufruf, Abhängigkeiten und erwartetes Ergebnis. Jonas startet noch einmal vom frischen Paket. Diesmal gelingt die erste Untersuchung ohne Hilfe. Vor dem Ende von Leas Stelle erprobt er auch die Anleitung zum nächsten Release.

MERKEN

Der Einstieg muss ohne die Projektumgebung funktionieren.

Wir liefern einen kleinen vollständigen Nutzungseinstieg und den gesamten bezeichneten Datenbestand. Ein anderer Rechner ist unser praktischer Gegencheck.

▼ Beispiel und Tipp

Beispiel: Statt eines Pfads zu Leas Netzlaufwerk sucht das Skript korpus.xml relativ zu seinem eigenen Ordner. Der Einstieg läuft mit Python-Standardbibliothek ohne API oder Konto.

Tipp: Dateinamen ohne betriebssystemspezifische Sonderzeichen und relative Pfade verwenden.

VOM FRISCHEN DOWNLOAD ZUM EIGENEN BEFUND

Ein Einstieg ohne Leas Rechner

Vom Download zur ersten Untersuchung

1. Das kleine Paket vollständig entpacken.
2. Mit Python 3.10 oder neuer `python untersuchen.py` im Paketordner ausführen.
3. Erwartetes Ergebnis: drei Rätsel, drei Lösungen und drei demonstrierte Formen.
4. In `ausgabe/` stehen Testeingaben, Referenzlösungen und ein Ergebnisnachweis getrennt bereit.

Nur Python-Standardbibliothek, kein Konto und keine API. Das Skript verwendet relative Pfade. Die TEI-Datei lässt sich auch mit anderen XML-Werkzeugen verarbeiten. Dieser Einstieg prüft Kennungen und Lösungsbezüge, kein TEI-Schema.

Nutzungseinstieg herunterladen ↓ · Anleitung als Markdown ↓

Was wird zusätzlich geprüft?

- Ist der maßgebliche Bestand erkennbar, sind Annotationen und Ableitungen erklärt?
- Funktionieren Dateinamen, relative Pfade und dokumentierte Abhängigkeiten in einer anderen Umgebung?
- Sind Datenrelease, Auswahl und Verfahren im Ergebnis nachvollziehbar?
- Kann eine Vertretung anhand der versionierten Pflegeanleitung einen lokalen Probe-Release erstellen?

Ein erfolgreicher Nutzungseinstieg schafft noch keine unbegrenzte Pflegekapazität. Kontakt und zugesagter Pflegeumfang bleiben sichtbar.

SO WÜRDEN WIR ES MACHEN

Das können Sie übernehmen

1. Dateinamen ohne betriebssystemspezifische Sonderzeichen und relative Pfade verwenden.
2. Einen Aufruf mit Abhängigkeiten und erwarteter Ausgabe in README dokumentieren.
3. Eine andere Person das frisch entpackte Paket ausführen lassen; Kontakt und Pflegezusage ergänzen.

Konkretes Beispiel

Statt eines Pfads zu Leas Netzlaufwerk sucht das Skript korpus.xml relativ zu seinem eigenen Ordner. Der Einstieg läuft mit Python-Standardbibliothek ohne API oder Konto.

Erledigt, wenn: Das dokumentierte Ergebnis entsteht in einer frischen Umgebung; fehlendes Wissen ist in der Anleitung ergänzt.

Git hilft dabei: Ein bezeichneter Release, vollständige lokale Daten, versionierte Beispiele und klare Änderungsnachweise ermöglichen selbstständige Nutzung. Die Anleitung für spätere Releases wird ebenfalls praktisch erprobt.

▼ Für Workshop und Selbststudium: eine Frage

Wo braucht jemand außerhalb unseres Teams noch Wissen, das nur in unseren Köpfen oder auf unseren Rechnern steckt?

THEMA 6 / DOWNLOADS UND ZUSATZDIENSTE

Die Bibliothek wartet auf den Server.

Lokale Daten sind unser Grundangebot.

Öffentlich und trotzdem nicht nutzbar

Elif möchte viele Rätsel lokal vergleichen. Die Bibliothek lädt sie einzeln über die API. Der Server drosselt die Anfragen; ihre Untersuchung bleibt stehen.

Ein unabhängiger Arbeitsweg

Das Team bietet den vollständigen Release zum Download an und lässt die Bibliothek auch lokale Dateien lesen. Eine kleine Probe führt zum ersten Ergebnis. API und Frontend bleiben zusätzliche Zugänge.

MERKEN

Korpusanalysen dürfen nicht vom laufenden Projektserver abhängen.

Unser Grundangebot sind versionierte lokale Daten und dokumentierte Exporte. Einen zusätzlichen Dienst richten wir erst für einen konkreten Bedarf und mit gesichertem Betrieb ein.

▼ Beispiel und Tipp

Beispiel: Zum Ausprobieren: nutzungsstart.zip. Für die vollständige Analyse: das bezeichnete Korpuspaket. Beide beschreiben ihre Dateien und den jeweiligen Umfang.

Tipp: Kleine Einstiegsdaten und vollständigen Release getrennt anbieten; große Bestände sinnvoll portionieren.

TEI + dokumentierte Exporte

Eigenständig nutzbare Daten; für den Einstieg sind Beispiele und Anleitung nötig.

▼ Beispiel und Tipp

Beispiel: Ein Datenpaket lässt sich lokal mit verschiedenen XML-Werkzeugen untersuchen.

Tipp: Das ist unser Grundangebot. Beispiele und Transformationen gehören dazu.

Bibliothek oder statische Ansicht

Erleichtert konkrete Aufgaben; Software und Beispiele müssen aktuell bleiben.

▼ Beispiel und Tipp

Beispiel: Eine Python-Bibliothek liest sowohl heruntergeladene Dateien als auch Daten über eine API.

Tipp: Den lokalen Weg zuerst zuverlässig machen; eine Oberfläche ergänzt die Daten.

Laufende Anwendung / API

Zusätzlicher Zugang mit Betrieb, Sicherheit, Wartung und Support.

▼ Beispiel und Tipp

Beispiel: Der Server liefert Einzeldaten, muss aber gewartet werden und kann Zugriffe begrenzen.

Tipp: Zusatzdienst erst bei konkretem Bedarf und zugesagtem Betrieb einrichten.

SO WÜRDEN WIR ES MACHEN

Das können Sie übernehmen

1. Kleine Einstiegsdaten und vollständigen Release getrennt anbieten; große Bestände sinnvoll portionieren.
2. Bibliothek und Beispiele auch mit lokalen Daten ausführbar machen.
3. API oder Frontend nur ergänzen, wenn Nutzen, Zuständigkeit und Betrieb geklärt sind.

Konkretes Beispiel

Zum Ausprobieren: nutzungsstart.zip. Für die vollständige Analyse: das bezeichnete Korpuspaket. Beide beschreiben ihre Dateien und den jeweiligen Umfang.

Erledigt, wenn: Die Untersuchung kann auch fortgesetzt werden, wenn die API ausfällt.

Git hilft dabei: Git versioniert Daten und Software. Es finanziert und betreibt keine zusätzlichen Dienste.

▼ Für Workshop und Selbststudium: eine Frage

Welcher konkrete Mehrwert rechtfertigt welches Betriebsversprechen?

THEMA 7 / PORTABILITÄT UND ERHALT

Der Host zieht um. Die Forschung soll bleiben.

Dateien und nötigen Kontext gemeinsam erhalten.

Mehr als Dateien umziehen

Beim Wechsel des Hosts sind die Git-Dateien vorhanden. Verknüpfte Diskussionen und Release-Anhänge fehlen jedoch. Einige Entscheidungen sind nur dort erklärt.

Den benötigten Kontext erhalten

Jonas übernimmt die notwendigen Plattforminformationen und hält fachliche Entscheidungen im Repo fest. Die Prüfungen laufen auch außerhalb der bisherigen Automatisierung. Archivierte Releases sichern die früheren Forschungsbezüge.

MERKEN

Git-Geschichte und Plattformbestand sind verschiedene Dinge.

Wir sichern Git, veröffentlichte Pakete und die für das Verständnis nötigen Entscheidungen. Der Neuaufbau wird anhand einer versionierten Anleitung geprüft.

▼ Beispiel und Tipp

Beispiel: Git überträgt Commits und Tags. Release-Anhänge, relevante Diskussionen und Diensteinstellungen werden zusätzlich übernommen oder nachvollziehbar dokumentiert.

Tipp: Git-Referenzen und benötigte Zusatzdateien sichern; relevante Issues und Entscheidungen exportieren oder dokumentieren.

Git-Daten

Dateistände, Commitbeziehungen und übertragene Referenzen. Tags und benötigte Zusatzobjekte ausdrücklich prüfen.

Zusätzlich erhalten

Relevante Issues und Entscheidungen, Anhänge, Prüfverfahren, CI-Konfiguration, Rollen, Zugänge und Kontaktwege.

Erhaltene Releases, vollständige Pakete und ein tatsächlicher Neuaufbau begrenzen Abhängigkeiten. Das Archiv ersetzt nicht automatisch einen laufenden Host.

SO WÜRDEN WIR ES MACHEN

Das können Sie übernehmen

1. Git-Referenzen und benötigte Zusatzdateien sichern; relevante Issues und Entscheidungen exportieren oder dokumentieren.
2. Prüfungen und Exporte ohne die alte CI-Umgebung ausführen.
3. Releasepakete, Zitiernachweise, Kontakt und Berechtigungen am neuen Ort prüfen.

Konkretes Beispiel

Git überträgt Commits und Tags. Release-Anhänge, relevante Diskussionen und Diensteinstellungen werden zusätzlich übernommen oder nachvollziehbar dokumentiert.

Erledigt, wenn: Die Dateien sind am neuen Ort verständlich und die dokumentierten Verfahren ausführbar.

Git hilft dabei: Git-Daten sind portabel; wissenschaftliche Archivierung und dokumentierte Verfahren begrenzen die Abhängigkeit von Plattformfunktionen.

▼ Für Workshop und Selbststudium: eine Frage

Was wäre nach dem Verlust des aktuellen Hosts tatsächlich noch ausführbar?